ETF 共同持股網路能預測股票報酬嗎？

指數股票型基金（ETF）透過持有一籃子股票追蹤指數。當多檔 ETF 同時持有相同股票，這些股票之間便形成一張「共同持股網路」。本研究在移除相對於全市場市值權重的機械性重疊之後，檢驗此一網路所承載的資訊結合殘差化價格共動網路，能否改善臺灣上市半導體與金融保險股票報酬的樣本外預測。在已測試的規格下答案為否定，且在檢驗過程中發現廣泛使用的評估指標本身存在估計量—校準不匹配。

否證 **在已測試的規格下（N ≈ 22–36、Ridge 與 XGBoost、2018–2025），六條方法論上互補的檢驗路徑一致指向：去偏 ETF 共同持股與殘差化價格共動之雙軌網路特徵，未能建立可偵測的增量選股預測力。**

黃晨瑋、鐘珮甄、黃苡晴 — 國立臺灣師範大學 學習科學學士學位學程 116 級畢業專題 — 2026

一、研究背景與問題

去偏 ETF 共同持股網路特徵在樣本外能否為個股報酬的橫斷面排序提供增量資訊，目前仍缺乏直接的實證檢驗。ETF 市場的擴張使共同持股效應成為近年資產定價文獻的焦點。Anton & Polk (2014) 發現透過共同基金持股相連的股票會展現超出基本面連結的報酬共動；Brown, Davies, & Ringgenberg (2021) 進一步指出 ETF 的申購贖回資金流會在成分股之間產生報酬可預測性。然而，市值加權 ETF 對大型股的持股重疊是機械性的。本研究的「去偏」指移除相對於全市場市值權重的機械性重疊：計算各股在每檔 ETF 中的持股權重與其全市場市值權重之差（市場相對權重），再以此計算股票間的相似度。此法可反映共同的超額配置或不定配置，但不等同於獨到基金的刻意投資決策，亦不完全消除被動指數成分。具體而言，產業型 ETF（例如半導體 ETF）的持股對象本就集中於特定產業，其成分股在該 ETF 中的權重必然高於全市場市值權重，因此去偏後的正相對權重有一部分來自產業授權的機械性效應，而非管理者的主動選擇。本研究的去偏程序移除的是「全市場層級」的市值重疊，但未進一步移除「產業層級」的授權效應。Cohen & Frazzini (2008) 的有限注意力機制針對的是供應鏈上的經濟連結；本研究假定相似的注意力不足亦可能存在於共同持股的脈絡中，但此一延伸尚待直接的理論支撐，而這正是本研究欲以樣本外資料檢驗的推論。

步驟一：計算各股票在每檔 ETF 中的市場相對權重（示意數字）

股票	市值權重	元大台灣50（廣基）	元大電子科技（產業型）	元大高股息（主題型）	相對權重向量
2330 台積電	28%	30%	25%	5%	[+2, −3, −23]
2454 聯發科	16%	18%	20%	3%	[+2, +4, −13]
3034 聯詠	3%	4%	15%	8%	[+1, +12, +5]
2379 瑞昱	2%	3%	14%	7%	[+1, +12, +5]
8299 群聯	1%	2%	5%	3%	[+1, +4, +2]

$w_{ij}^{rel} = w_{ij}^{ETF} - w_j^{mkt}$

例：台積電在元大50 = 30% − 28% = +2%

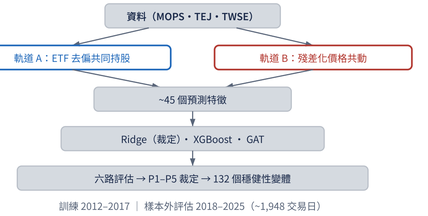
聯詠 [+1,+12,+5]
瑞昱 [+1,+12,+5] → 向量幾乎相同

步驟二：計算餘弦相似度 → 建立去偏網路（保留 K=30 最近鄰）

CosSim(聯詠, 瑞昱) = [+1,+12,+5] · [+1,+12,+5] / (‖ [+1,+12,+5] ‖²) = 1.00（完全相同） → 強連結

CosSim(台積電, 聯詠) = [+2,−3,−23] · [+1,+12,+5] / (‖ ⋯ ‖ · ‖ ⋯ ‖) ≈ −0.82（方向相反） → 無連結

結果：網路結構的改變



數字為示意，非實際持股資料。產業型 ETF（如元大電子科技）的超額配置有一部分來自授權而非主動選擇（見限制章節）。

去偏公式：

$$w_{ij}^{rel} = w_{ij}^{ETF} - w_j^{mkt}$$

兩股票間的去偏共同持股相似度（餘弦相似度）：

$$\mathrm{CosSim}(i,k) = \Sigma_j\, w_{ij}^{rel} \cdot w_{ik}^{rel} \,/\, (\,\|\, w_{\cdot i}^{rel} \,\|\, \cdot \,\|\, w_{\cdot k}^{rel} \,\|\,)$$

w_{ij}^{ETF}：股票 j 在 ETF i 中的持股權重。

w_j^{mkt}：股票 j 的全市場市值權重（市值 / 全市場總市值）。

w_{ij}^{rel}：市場相對權重。正值表示 ETF i 對股票 j 超額配置；負值表示不足配置。

$\mathrm{CosSim}(i,k)$：股票 i 與 k 在所有 ETF j 的市場相對權重向量之餘弦相似度。值越高表示兩檔股票被 ETF 群以相似的模式超額或不足配置。保留相似度最高的 K=30 個鄰居。

本研究以臺灣半導體股票（訓練期每季約 22 檔、評估期約 36 檔）為主要場域，金融保險股票（約 22–26 檔）為比較產業。樣本限於至少被兩檔 ETF 持有、於該季具有效產業分類與上市地位的普通股。五項可檢驗命題與裁定規則均於分析之前載明於計畫書中，旨在限制研究者自由度；後續修訂已揭露於下方修訂軌跡。

資料概覽

資料來源	涵蓋	規模
MOPS ETF 持股	2004Q1–2025Q4（88 季）	108,881 列、76 檔基金、1,059 檔個股
TEJ 個股日股價	2012-05-02 起	上市普通股面板，含已下市標的
TEJ 多因子模組	2000–2026	Fama–French 五因子（FF5）＋動量因子（日頻），代號 Y9999（上市）
TWSE 三大法人	2012-05-02 起	3,348 個交易日（含 12 個補行交易日）
TWSE 產業分類	2012Q2–2025Q4	Internet Archive 快照重建，前視違規 0

半導體與金融保險兩產業面板。訓練期 2012Q4–2017Q4（約 5.2 年），樣本外評估期 2018Q1–2025Q4（1,943–1,948 個可用交易日，隨預測期距 H 而異）。半導體業訓練期平均 22.1 檔、評估期 36.4 檔；金融保險業樣本在 22–26 檔。前視違規 0（產業分類以 Internet Archive 快照重建；訓練期 16 季使用回填資料）。

二、研究設計

訓練 2012–2017 ｜ 樣本外評估 2018–2025（~1,948 交易日）

本研究的主要檢驗是比較無網路基線 M0 與加入雙軌網路特徵的完整模型 M1：若 M1 在已測試的規格下未能顯著擊敗 M0，則未能建立網路特徵的增量預測力。兩條平行的網路軌道如下：軌道 A 基於 ETF 的季度持股揭露，計算每對股票在市場相對權重（ETF 持股權重減去全市場市值權重）上的餘弦相似度，保留最相似的 K=30 個鄰居（K 為最大保留鄰居數）。軌道 B 基於股價的殘差共動，先以六個共同因子加一個產業特定因子殘差化個股日報酬（詳見論文 §5.2），再以滾動 52 週窗口計算殘差相關。兩條軌道合計提供 24 個網路特徵，連同 10 個個股特徵與 11 個市場控制變數（其中 1 個因缺失而未使用），候選特徵共 45 個；經篩選後 M1 實際配適約 42 個。

預測模型採用 Ridge 迴歸（一種帶 L2 懲罰的線性模型，事前指定為裁定模型，即正式命題裁定以其結果為準，其餘模型提供描述性參照）與 XGBoost（一種梯度提升樹模型）。模型每季以全部歷史資料重新配適，在 2018–2025 年進行樣本外預測。穩健性檢核涵蓋 132 個設定變體（含 99 次排列安慰劑、10 次 iid 抽取及基準設定），此 132 包含安慰劑抽取，非 132 種獨立模型設計。

特徵群組	欄位數	角色	M0	M1
個股特徵	10	單股基線	✓	✓
市場控制	11	控制群組	✓	✓
ETF 軌道	12	實驗變數	—	✓
價格軌道	12	實驗變數	—	✓

候選特徵 45 個（11 個市場控制中 1 個因缺失未使用，故實際候選 44 個）。M0 保留約 20 個；M1 加入兩條軌道的 24 個網路特徵，經篩選後實際配適約 42 個。

三、五項命題裁定

P1 在嚴格規則下不可裁定，P2–P4 不支持，P5 因 P3 未通過而不予裁定。裁定標準於分析前載明於計畫書（H 為交易日預測期距）。

命題	內容	裁定	依據
P1	網路可預測半導體報酬	*無法裁定*	嚴格解讀下安慰劑+統定力規則排除所有期距（空集）；限定裁定模型 Ridge 後 H=5 與 H=20（或 H=30）可用，但 Ridge 仍未達支持標準。H=60 因穩定力不足僅供描述
P2	去偏程序為必要	不支持	移除去偏後未觀察到符合裁定門檻的顯著惡化
P3	半導體效果強於金融	不支持	交互作用 F 檢定全不顯著（p = 0.17–0.75）
P4	涵蓋度越高效果越強	不支持 ↺	係數方向與預期相反（係數方向非樣本外預測力之充分條件）
P5	差異來自價格軌道	*不予裁定*	條件於 P3

原始假設的修訂軌跡

六項事後修訂全部使否證結論更強或維持中性，無一使裁定從「不支持」轉為「支持」。此一方向性觀察降低了修訂被導向正面結論的疑慮，但不能完全排除偏向否證敘事的可能。

修訂	性質	方向
P4 $\chi^2 \to F$	修正過度拒絕的參考分布	支持→不支持
Hodrick 5.8× 膨脹	修正公式錯誤	中性
U19 正規化	市場層級特徵經橫斷面正規化後塌縮為 $1/N_t$（特徵工程缺陷，已修正）	金融有→兩側皆無
BH 多重比較	報告 32 個比較；Benjamini–Hochberg（BH）錯誤發現率控制分模型施加，每組 8 個檢定	中性
P3 配對→全樣本	配對前提不成立	不變
Clark–West（CW）大小	發現 CW 檢定在 XGBoost 上過度拒絕	不變

計畫書第 3 章保留原文一字不改，修訂以視覺區隔的框呈現，供讀者獨立覆核。

如何閱讀本海報的核心指標

R^2_{OOS}	本海報報告的增量樣本外 R^2 是以無網路基線 M0 為分母：$R^2_{OOS}(M1{:}M0) = 1 - MSE(M1) / MSE(M0)$。正值表示 M1 的預測誤差低於 M0，負值表示更高。例如 −0.35% 表示 M1 的平方誤差比 M0 的高出 0.35%。
合併 R^2	將所有股票在所有交易日的預測值成一個數字。問題在於它混合了兩種能力：區分同一天內哪些股票漲跌（選股）和判斷市場整體方向（擇時）。本研究的目標是選股，但合併指標可能被擇時分量主導。
選股 R^2	橫斷面 R^2（R^2_{CS}）：衡量 M1 相對 M0 在同一天內個股報酬偏差上的平方誤差縮減程度。此指標對預測值的尺度敏感：保序的正向縮放可改變 R^2_{CS} 而不改變排序。排序能力由 IC 另行衡量。
IC	資訊係數（Information Coefficient），定義為每日預測值與實現報酬的 Spearman 等級相關。IC > 0 表示預測排序與實際漲跌方向一致。本研究以 IC 增量（IC(M1) − IC(M0)）判斷加入網路特徵後排序是否改善。
淨選股增益	$R^2_{CS}(M1) - R^2_{CS}(M0)$，其中 M0 是將基線預測縮放至與 M1 相同離散度後的版本。此指標排除了「M1 只是因為離散度較小而得分」的可能，是事後診斷工具而非因素推論。
增量選股資訊	加入網路特徵後，模型是否能比不含網路的基線（M0）更好地區分同一天內哪些股票會漲、哪些會跌。「增量」是相對於 M0 已有的預測能力而言：M0 已使用個股與市場特徵，問的是網路特徵能否在此之上再提供額外的橫股排序資訊。
增量預測關聯	Fama–MacBeth 迴歸中的概念。在每個交易日，用 M0 和 M1 的預測值同時去解釋實際報酬的橫斷面差異。若 M1 的係數（γ_1）顯著異於零，表示 M1 在控制 M0 之後仍具橫斷面報酬有額外的線性關聯。此處的「關聯」不等同於識別已定價風險因子。本研究八格 p = 0.26–0.90，遠離顯著。

四、裁定模型的分解結果

裁定模型 Ridge 在八格主規格中，合併 R^2、選股 R^2 與淨選股增益全為負值。三個指標全為負意味著：無論用哪一種衡量方式，加入雙軌網路特徵後的 M1 預測都不如無網路的 M0 基線。

產業 × 預測天數	合併 R^2	選股 R^2	淨選股增益
半導體 5 日	−0.10%	−0.17%	−0.11%
半導體 20 日	−0.35%	−0.60%	−0.31%
半導體 30 日	−0.49%	−0.80%	−0.39%
半導體 60 日	−0.71%	−1.03%	−0.26%
金融 5 日	−0.05%	−0.12%	−0.08%
金融 20 日	−0.15%	−0.36%	−0.35%
金融 30 日	−0.26%	−0.57%	−0.55%
金融 60 日	−0.48%	−0.90%	−0.67%

八格全負。在已測試的 Ridge 規格下，加入雙軌網路特徵未能改善預測。

檢定力與裁定判讀

負結果應連同設計的偵測能力解讀。最小可偵測效果（minimum detectable effect, MDE）是在特定資料生成過程與檢定設定下估計的效果量尺度。

BH 最保守門檻下的 MDE（R^2 效果量，以百分比表示）

預測期距	半導體	金融保險
5 日	0.06%	0.05%
20 日	0.16%	0.25%
30 日	0.30%	0.30%
60 日	0.45%	0.50%

來源：本研究檢定力模擬（論文 §8.6）。MDE 依模擬假設而定，並非實現效果的上信賴界限，也不能直接作為事後淨選股增益的關著性門檻。60 日期距事前標記為檢定力不足，僅供描述。

三種裁定如何理解

不支持　本次檢驗未達支持標準，不等同於證明效果不存在。
無法裁定　事前規則限制使正式裁定無法成立；P1 的嚴格規則屬此情況。
不予裁定　前提命題未成立，因此不進行後續裁定；P5 以前提 P3 為條件。

在已測試的規格下未能建立增量預測力；低於設計偵測能力的效果，以及其他市場與模型下的效果，仍屬未決。

五、安慰劑檢驗與配對崩潰

排列安慰劑在每個產業—季度區塊內隨機重新指派股票代號與網路特徵區塊的對應關係，保留區塊內的特徵結構與變異，僅打斷「哪檔股票對應哪組鄰居特徵」。若真實的網路配對攜帶資訊，其表現應顯著優於 99 次隨機重配（$p < 0.05$）。

	5 日	20 日	30 日	60 日
半導體 Ridge	0.83	0.90	0.95	0.92
半導體 XGBoost	0.12	0.29	0.47	0.53
金融 Ridge	0.34	0.42	0.51	0.54
金融 XGBoost	0.63	0.27	0.22	0.19

16 格未調整排列 p 值（基於合併 R^2，非 IC）無一低於 0.05（最小 0.12）。在此隨機化方案下，未偵測到真實網路配對優於隨機重配的證據。

P3 的跨產業配對檢定原擬以傾向分數配對控制 ETF 涵蓋密度，但可配對性在評估期大幅下降（非嚴格單調，個別季度有局部回升）：



圖為金融保險股中可與半導體配對之比例的年度中位數。2020 年後急劇下降（2024 年有 4.3% 的局部回升）。32 個評估季度中僅 9 季保留至少 5 對配對，且全部集中於 2021Q1 之前；之後配對前提不成立。

六、經濟顯著性

在最嚴格的成本條件下（H=20、零售費率、年化借券費 3%、最大市場衝擊係數 0.003），M1 在 16 個格子（2 產業 × 4 模型 × 2 排序方式；三分位與五分位）中無一取得正的淨夏普比率（最佳 −0.007），M0 則有 1 格為正（+0.308）。即使不扣成本，H=20 三分位多空策略中 M0 在 8 格中贏 7 格。放寬至全部 1,536 個成本切片（4 期距 × 多成本情境），M1 有 564 格為正（最大 0.730），M0 有 957 格為正（最大 0.853）。M1 在任何成本設定下均未系統性地優於 M0。

圖一：合併指標的正值不等同於增量選股資訊（XGBoost，主規格，M1 vs M0）

合併 R^2（藍色）衡量整體預測準確度，包含選股與擇時兩個維度。橫斷面 R^2（紅色）僅衡量選股能力。此圖的關鍵訊息是：XGBoost 的合併 R^2 有時為正（藍色條形向右），但所出選股分量後大多為負（紅色條形向左），表示其表面上的改善可能來自擇時與離散度的縮減，而非真正更好的選股排序。

圖二：統計檢定工具的可靠度

Clark–West 檢定用於判斷「新模型是否顯著優於舊模型」。理想情況下，當兩個模型實際上一樣好時，此檢定應僅有約 5% 的機率誤判為「新模型較優」（下圖虛線）。在本資料集的 99 次排列實驗中（掃描規格；名目 α=0.05），Ridge 的拒絕率接近名目水準（0.02–0.07），XGBoost 則大幅超過（0.25–0.99）。此結果揭示的是已測試的資料、模型設定與隨機化方案，不構成 CW 檢定在所有 XGBoost 應用上無效的一般性結論。

圖三注意力網路（Graph Attention Network, GAT）

為什麼需要 GAT？ Ridge 和 XGBoost 使用的是人工設計的網路特徵（例如鄰居報酬均值、加權相關等），這些特徵的計算方式由研究者事先決定。一個自然的問題是：是否因為人工特徵的設計不夠好，才導致網路資訊無法被提取？GAT 是一種能直接在圖結構上運算的神經網路，它透過「注意力機制」自動學習每個鄰居的重要性權重，不需要人工指定如何彙總鄰居資訊。GAT 的負結果擴大了已測試方法的範圍，但不能排除其他圖架構或訓練協定可能成功的可能性。

產業	5 日	20 日	30 日	60 日
半導體	−2.3%	−7.1%	−10.2%	−6.9%
金融	−5.8%	−9.4%	−11.9%	−9.6%

結果解讀：合併 R^2（GAT M1 vs Ridge M0 基線）8 格全負（平均 −7.9%）。此比較以 Ridge M0 為基準，而非 GAT 自身的有過/無過消融實驗，因此反映的是整條 GAT 管線（含注意力機制與訓練協定）相對於 Ridge 基線的綜合表現。負結果可能受限於小樣本（N ≈ 22–36）下神經網路的過度配適。結合 Ridge 和 XGBoost 的結果，三種不同架構皆未勝過 M0，擴大了已測試方法的範圍。

Fama–MacBeth 增量迴歸：第四條互補路徑

裁定模型 Ridge 的增量係數 γ_1 在八格全部不顯著（p = 0.26–0.90）。Fama–MacBeth 迴歸逐日跑橫斷面普通最小平方法（OLS），檢驗 M1 的預測在控制 M0 之後是否仍有增量的橫斷面預測關聯（γ_1 顯著異於零即表示有增量）。

產業	5 日	20 日	30 日	60 日
半導體 γ_1	−0.04	−0.26	−0.29	−0.04
p 值	0.84	0.30	0.26	0.86
金融 γ_1	0.05	0.04	0.07	0.24
p 值	0.84	0.90	0.81	0.38

八格的 p 值介於 0.26–0.90，遠離 0.05 門檻。在此檢驗下未能建立 M1 對 M0 的增量橫斷面預測關聯。

七、穩健性與延伸分析

在兩種懲罰網格設定下，Ridge 的資訊係數（IC，即預測值與實現報酬的日橫斷面 Spearman 相關）增量在 8 格中無一為正。132 個設定變體涵蓋鄰居數敏感度（K = 15, 20, 30, 50）、99 次排列安慰劑等。不範性案例：交叉驗證在半導體 H=60 上選出的 Elastic Net 最佳模型為 42 個係數全為零的空模型，所有股票在同一天得到完全相同的預測，選股資訊依定義為零，然而合併 R^2 仍為正值（+0.326%），構成離散度匹配診斷的直接示範。

ETF 類型切分（XGBoost 合併 R^2，掃描規格，機制診斷用途）

論文 §5.1 預測去偏後市值加權 ETF 貢獻近乎為零，故預期僅用市值加權廣基 ETF 建構的網路（cap_broad 變體）應大幅衰減。金融倒符合此一預期，但半導體倒方向相反。此結果來自掃描規格而非主規格（主規格見圖一），為機制診斷而非增量選股資訊的正面證據。

變體 × 產業	5 日	20 日	30 日	60 日
base 半導體	+0.14%	+0.57%	+0.14%	−0.39%
cap_broad 半導體	+0.17%	+0.98%	+0.60%	+0.22%
base 金融	+0.12%	+0.75%	+1.05%	+0.15%
cap_broad 金融	−0.01%	+0.56%	+0.62%	−1.22%

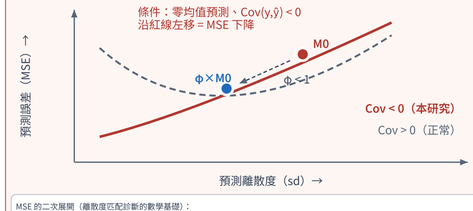
半導體倒 cap_broad 在 H=20/30/60 的合併 R^2 皆優於完整網路 base，顯示去偏後殘餘的大型股成分在半導體倒仍為主要來源（排除台積電後大幅衰減為佐證，詳見論文 §9.4）。注意：合併 R^2 的正值不等同於增量選股資訊（見圖一及下方離散度匹配診斷）。

八、限制與效力邊界

本研究的橫斷面規模（N ≈ 22–36）約為 Gu, Kelly, & Xiu (2020) 所使用的美國橫斷面（N ≈ 3,000–10,000）的百分之一，外推需謹慎。Ridge 的交叉驗證 216 次中 216 次選到懲罰項上界（據歷史穩校紀錄，當前匯出的 fit log 未含 best_alpha），顯示模型偏好常數預測，其有效容量可能不足以擷取極弱訊號。Clark–West（CW）在 XGBoost 上的大小失真可能為小樣本所特有；LightGBM 與 CatBoost 未獨立重測。M1 同時包含 ETF 軌道 A 與價格軌道 B，負結果不能單獨歸因於其中一條軌道（論文 §9.3 的描述性單軌消融分析顯示 Ridge 16 格皆負，但正式的 P5 閘門未通過）。六條檢驗路徑使用不同的統計工具（方法論上互補），但共享同一組預測輸出與訓練協定。

去偏程序的另一項限制是：市場相對權重無法區分三種來源：(1) 產業型 ETF 的被動授權（半導體 ETF 必然超額配置半導體股）、(2) 指數方法論差異（等權 vs 市值加權）、(3) 管理者的主動配置。本研究僅移除全市場層級的市值重疊，產業層級的授權效應仍保留在特徵中。研究樣本的 76 檔 ETF 中有 8 檔為產業型（10.5%）；半導體相關 5 檔（元大電子科技自 2007 年起全程存在）；富邦核心半導體自 2021Q2 起；台新半導體精選 30 自 2022Q1 起；群益半導體收益自 2023Q2 起）、金融相關 2 檔（元大金融全程存在；富邦金融 2008–2019 已下市）、綠能電動車 1 檔（2021Q3 起）。評估期每季產業型 ETF 估全部 ETF 的 10–16%。事後敏感度檢查：以產業內市值權重取代全市場基準重跑 132 變體，Ridge IC 增量仍 0/8 正、排列 p 值 16 格皆 > 0.05（最小 0.18）。但此基準未完全移除產業配置（B − c = (a−1)c ≠ 0），為穩健性證據而非完全辨識。

次要方法論發現：合併 R^2 的估計量—校準不匹配



MSE 的二次展開（離散度匹配診斷的數學基礎）：

$$MSE = \mathrm{Var}(y) + \mathrm{Var}(\hat{y}) - 2\,\mathrm{Cov}(y,\hat{y}) + (\bar{\hat{y}} - \bar{y})^2$$

當預測去均值（$\bar{\hat{y}} = \bar{y} = 0$）時，簡化為：

$$MSE = \mathrm{Var}(y) + \mathbf{Var(\hat{y})} - 2\,\mathrm{Cov}(y,\hat{y})$$

對一組固定的去均值預測 ρ，將其乘以正確放因子 c：$\mathrm{MSE}(c\rho)$ 對 c 的導數 $= 2c\,\mathrm{Var}(\rho) - 2\,\mathrm{Cov}(y,\rho)$。

若 $\mathrm{Cov}(y,\rho) < 0$，此導數在正，故縮小 c 即降低 MSE，同時保留排序不變。

y：實現報酬（觀測值），即股票在預測期距結束後的實際累積報酬。

$\hat{y}$：模型預測值，即 Ridge 或 XGBoost 對該股票未來報酬的樣本外預測。

$\mathrm{Var}(\cdot)$：變異數，衡量一組數值偏離其均值的離散程度。$\mathrm{Var}(\hat{y})$ 即「預測離散度」。

$\mathrm{Cov}(y,\hat{y})$：共變異數，衡量實現報酬與預測值的共同變動方向。正值表示預測方向與實際一致，負值表示系統性地反向。

μ：實現報酬的均值；$\hat{\mu}$：預測值的均值。去均值後兩者皆為零。

MSE：均方誤差（Mean Squared Error），預測誤差的平方平均值。本研究的 $R^2_{OOS} = 1 - \mathrm{MSE}(M1) / \mathrm{MSE}(M0)$，故 M1 的 MSE 越低於 M0，$R^2$ 越高。

φ：離散度匹配的縮放因子，定義為 $\mathrm{sd}(\hat{y}_{M1}) / \mathrm{sd}(\hat{y}_{M0})$。反事實預測為 $\hat{y}_0^* = \mathrm{mean}(\hat{y}_0) + \varphi(\hat{y}_0 - \mathrm{mean}(\hat{y}_0))$，保留均值、僅改變離散度。$\varphi$ 可大於或小於 1，故此操作為「離散度匹配」而非僅「縮減」。合併與橫斷面各有獨立的 φ 值。

合併樣本外 R^2（pooled out-of-sample R^2）是 Campbell & Thompson (2008) 以來報酬可預測性文獻廣泛採用的標準評估量，Gu, Kelly, & Xiu (2020) 在機器學習資產定價的基準研究中亦以此為主要指標。然而，此一指標在面板追蹤資料的脈絡下混合了兩個可能方向相反的維度：橫斷面（在同一天內區分個股漲跌的能力，即選股）與時序（判斷整體市場方向的能力，即擇時）。本研究的目標是選股，但合併指標被擇時分量主導。

上方公式揭示了關鍵機制：當預測值已去均值且 $\mathrm{Cov}(y,\hat{y}) < 0$ 時，MSE 中的 $-2\,\mathrm{Cov}$ 項變為正值，使 MSE 對預測離散度單調遞增（如上圖紅線所示）。此時任何使預測值更集中的改動，即便完全不攜帶選股資訊，都能機械性地降低預測誤差。改善校準（減少不必要的離散度）本身是合理的建模改進，但它不等同於增加新的排序資訊。

歷史診斷（修正前 U19 規格）：修正前半導體 15/16 格的時序相關為負。修正前三種樹模型（XGBoost、LightGBM、CatBoost）合計 23 格正合併 R^2 增益中，離散度匹配的反事實縮放可複製其中大部分（歷史計算的確切比例因修正前配置已不可重建而未獨立驗證）。**修正後（當前結果）：**半導體 XGBoost H=20 的離散度匹配複製比例為 68.8%，即非全部正增益皆由此通道解釋。示範案例：半導體 H=60 的 Elastic Net 空模型（42 個係數全為零，選股資訊依定義為零），合併 R^2 仍為 +0.326%。

與既有文獻的定位

此一發現的數學基礎（MSE 的二次展開）是教科書內容（Elliott & Timmermann, 2016）。在本研究的文獻搜尋範圍內（截至 2026 年 9 月），尚未發現有文獻明確指出合併 R^2 在基線擇時為負時會系統性地奠動離散度縮減。最接近的是 Engelberg, McLean, Pontiff, & Ringgenberg (2023) 發現橫斷面預測因子的樣本外時序預測力有限，以及 Rapach & Zhou (2020) 分開定義時序與橫斷面 R^2，但兩者皆未涉及合併指標的離散度匹配機制。本研究將此定位為已知數學性質在面板報酬預測脈絡下的一個量化應用與診斷程序。

Clark–West 檢定在 XGBoost 上的大小失真

Clark & West (2007) 檢定是判斷巢狀模型預測優劣的標準工具。本研究以 99 次排列安慰劑（掃描規格；名目 α=0.05）實測其虛無拒絕率，發現在截定模型 Ridge 上為 0.02–0.07（接近名目水準），在 XGBoost 上則高達 0.25–0.99（大幅超過名目水準；LightGBM、CatBoost 未獨立量測）。此結果描述的是已測試的資料、模型設定與隨機化方案。Escanciano & Parra (2026) 從理論分析此類檢定在機器學習方法上的有效性條件，要求損失函數與估計量具備適當相容性且預測收斂足夠快。本研究的排列安慰劑數字提供了在小樣本面設計下的一組設計特定實證證據，範圍較此理論分析為窄。

可移植的檢驗程序

本研究據此提出一套適用於任何使用合併 R^2 且基線擇時為負的研究的檢驗程序：對指標本身施加安慰劑，即將一個理論上不應產生效果的改動施加於指標，觀察其是否產生反應。此程序的成本趨近於零（一行反事實計算），但揭露力可以是決定性的。任何報告合併 R^2 的研究，宜先檢查基線模型的時序相關符號；若為負，合併 R^2 的正值即有可能為收縮假象。

本研究之貢獻

在實質面，本研究為去偏 ETF 共同持股與殘差化價格共動之雙軌網路特徵的橫斷面預測力提供了一份否證記錄。截定模型 Ridge 在兩個產業、四個預測期距、兩種懲罰網格設定下的 IC 增量（IC(M1) − IC(M0)）無一為正（IC 為預測值與實現報酬的日橫斷面 Spearman 相關），且此符號結論在兩種網格下一致。六條方法論上互補的評估路徑對此結出一致的答案：

⑤ Ridge 合併 R^2 在 23/24 子期間格為負（例外：金融 2018–2019 H=20, +0.13%）。
⑥ 240 日逐點滾動 CW 診斷，非正式路徑檢定。

上述研究也產生了以下次要的方法論診斷。其一，以離散度匹配診斷量化了合併 R^2 在基線擇時技能為負時的離散度縮減效應，此為已知 MSE 性質的量化應用，任何使用此指標的面板報酬預測研究都可能遇到。其二，在小橫斷面設計下以排列安慰劑量化了 Clark–West 檢定在 XGBoost 上的大小失真（虛無拒絕率 0.25–0.99，對照截定模型 Ridge 的 0.02–0.07；LightGBM、CatBoost 未獨立量測），與 Escanciano & Parra (2026) 的理論分析方向一致。其三，提出可移植的「對指標施加安慰劑」檢驗程序，即對指標施加一個理論上不應產生效果的改動並觀察其是否產生反應。此程序適用於任何使用合併 R^2 且基線擇時為負的研究。

在已測試的規格下（臺灣上市半導體與金融保險股、N ≈ 22–36、訓練期 2012–2017、評估期 2018–2025、Ridge 與 XGBoost），本研究未能建立去偏 ETF 共同持股與殘差化價格共動之雙軌網路特徵的統計顯著增量預測力。M1 同時包含兩條軌道，負結果不能單獨歸因於其中一條（描述性單軌消融分析顯示 Ridge 16 格皆負，但正式的 P5 閘門未通過）。低於本設計偵測能力的效果、以及在橫斷面規模較大的市場（如美國，N ≈ 3,000–10,000）、其他產業、或以其他模型萃取時的效果，仍屬未決。

主要參考文獻　Anton & Polk (2014, *JF*) ・ Brown, Davies & Ringgenberg (2021, *RoF*) ・ Campbell & Thompson (2008, *RFS*) ・ Clark & West (2007, *JoE*) ・ Cohen & Frazzini (2008, *JF*) ・ Elliott & Timmermann (2016, Princeton UP) ・ Engelberg, McLean, Pontiff & Ringgenberg (2023, *JFQA*) ・ Escanciano & Parra (2026, *JBES*) ・ Gu, Kelly & Xiu (2020, *RFS*) ・ Rapach & Zhou (2020, Wiley)

© 2026 黃晨瑋、鐘珮甄、黃苡晴　All rights reserved.
國立臺灣師範大學 學習科學學士學位學程 116 級畢業專題